

BÁO CÁO LAB 3: CNN for CIFAR-10 Image Classification

Sinh Viên: Nguyễn Trọng Phúc

MSSV: 23120332

1. Mức độ cải thiện hiệu năng của CNN so với MLP (Accuracy và F1-score)

Dựa trên dữ liệu ghi nhận từ các tệp kết quả thực nghiệm công bố trong thư mục, cấu trúc Convolutional Neural Network (CNN) mang lại một bước nhảy vọt về hiệu năng phân loại so với mạng fully connected truyền thống Multi-Layer Perceptron (MLP):

- Số liệu thực nghiệm cụ thể:

Chỉ số (Metrics)	Mô hình Baseline MLP (cifar_mlp)	Mô hình Custom CNN (cnn)	Mức độ cải thiện (Chênh lệch)
Độ chính xác (Test Accuracy)	51.25%	84.31%	33.06% (Tăng ~64.5% hiệu năng tuyệt đối)
F1-score (Weighted Avg)	50.93%	84.30%	33.37%
Tổng lượng tham số (Weights)	1,707,274	816,938	Giảm 52.16% (Ít hơn một nửa tham số của MLP)

Sự hạn chế của MLP (Cơ chế Duỗi phẳng - Flatten): Để đưa ảnh vào mạng MLP, ta bắt buộc phải sử dụng lớp Flatten(), biến ma trận không gian 2D thành một vector tuyến tính 1D phẳng dài 3072 phần tử. Hành động này vô tình làm phá hủy hoàn toàn cấu trúc không gian cục bộ (Spatial Correlation) của các pixel nằm cạnh nhau. Mạng liên kết

đầy đủ (Fully Connected) buộc phải học mọi mối tương quan từ đầu một cách mù quáng, dẫn đến bùng nổ tham số (1.7 triệu kết nối) nhưng mô hình vẫn dễ rơi vào trạng thái "học vẹt", cực kỳ nhạy cảm với sự dịch chuyển của vật thể.

Sự tối ưu vượt trội của CNN (Cơ chế Tích chập & Chia sẻ trọng số): Trái lại, CNN xử lý trực tiếp trên Tensor ảnh 3D thông qua các bộ lọc (Kernel/Filter) trượt cục bộ. Nhờ nguyên lý chia sẻ trọng số (Weight Sharing) và tính bất biến tịnh tiến (Translation Invariance), một Kernel có thể trích xuất các đặc trưng như đường cạnh, hình khối ở mọi vị trí trên ảnh mà không cần tăng lượng tham số. Nhờ vậy, CNN đạt F1-score bứt phá lên 84.30% trong khi chỉ sử dụng chưa đầy một nửa số lượng tham số so với MLP.

2. Các lớp khó phân loại nhất và phân tích yếu tố thị giác dựa trên Confusion Matrix

- Dựa trên dữ liệu chi tiết từ Classification Report của cả hai mô hình, ba lớp có chỉ số F1-score thấp nhất và chịu ảnh hưởng nặng nề nhất lần lượt là:
- Lớp 3 (Cat - Mèo):** F1-score đạt 37.54% (MLP) $\rightarrow$ nâng lên 69.66% (CNN).
- Lớp 5 (Dog - Chó):** F1-score đạt 38.34% (MLP) $\rightarrow$ nâng lên 76.82% (CNN).
- Lớp 2 (Bird - Chim):** F1-score đạt 38.21% (MLP) $\rightarrow$ nâng lên 79.07% (CNN).
- Phân tích sâu ma trận nhầm lẫn (Confusion Matrix) chỉ ra **Top 3 cặp lớp bị nhầm lẫn nhiều nhất** đi kèm diễn giải yếu tố thị giác sâu bên dưới cấu trúc ảnh:
- Cặp 1: Lớp 3 (Cat) và Lớp 5 (Dog) [Sự tương đồng cấu trúc cao - High Intra-class Similarity]**
 - Minh chứng số liệu:* Ở mạng MLP, có tới 260 ảnh Chó bị nhận diện sai thành Mèo, và 133 ảnh Mèo bị nhầm thành Chó. Đối với mạng CNN, tỷ lệ nhầm lẫn giảm mạnh nhưng vẫn đứng đầu bảng lỗi: **143 ảnh Chó bị nhầm thành Mèo và 98 ảnh Mèo bị đoán thành Chó.**
 - Yếu tố thị giác (Visual Factors):* Chó và mèo chia sẻ chung các đặc trưng hình thái học (morphological features) tương đồng lớn: đều là động vật bốn chân có đuôi, cấu trúc phân bố lông, và hình dáng khuôn mặt tròn/mồm ngấn khi nín xuống độ phân giải siêu thấp 32 x 32 sẽ bị mờ nhòe hoàn toàn các chi tiết phân tách mịn (fine-grained features) như cấu trúc đồng tử mắt hay chi tiết mũi, dẫn đến ranh giới quyết định (decision boundary) của mô hình bị chòng lỉnh rất mạnh.

- **Cặp 2: Lớp 1 (Automobile) và Lớp 9 (Truck) [Đặc trưng hình học nhân tạo chồng lấn - Rigid Geometric Features]**
- *Minh chứng số liệu:* Mạng MLP nhằm 226 ảnh Xe tải sang Ô tô. Mạng CNN ghi nhận **50 ảnh Xe tải bị đoán nhầm thành Ô tô và 43 ảnh Ô tô nhầm sang Xe tải.**
- *Yếu tố thị giác (Visual Factors):* Cả hai đối tượng này đều có kết cấu hình học nhân tạo cứng (vỏ kim loại phẳng, các góc cạnh thẳng, bánh xe tròn) và thường xuất hiện đồng thời trên cùng một môi trường ngữ cảnh (đường nhựa, cao tốc). Điểm phân biệt bản chất là độ dài thùng xe hoặc tỷ lệ trục bánh xe rất dễ bị che lấp hoặc thay đổi mạnh do góc chụp góc nghiêng (perspective distortion), đánh lừa bộ lọc tích chập.
- **Cặp 3: Lớp 3 (Cat) và Lớp 2 (Bird) / Lớp 6 (Frog) [Nhiều phong nền đồng nhất - Background Bias]**
- *Minh chứng số liệu:* Mạng MLP nhận diện sai 201 ảnh Mèo thànhẾch. Mạng CNN ghi nhận **62 trường hợp ảnh Mèo bị nhầm thành Chim.**
- *Yếu tố thị giác (Visual Factors):* Mèo, chim và ếch thường xuyên xuất hiện trên các phong nền tự nhiên có màu sắc tương tự (thảm cỏ xanh, cành cây non, hoặc đất màu nâu bụi bụi). Khi mô hình không đủ sâu để tách biệt đối tượng chính ra khỏi phong nền (object-background disentanglement), nó sẽ có xu hướng trích xuất nhầm các đặc trưng ngữ cảnh của phong nền làm đặc trưng phân loại, gây ra lỗi nghiêm trọng này.
-

3. Phân tích hiện tượng Overfitting qua đường cong học tập (Learning Curves)

Để kết luận định lượng về việc Tăng cường dữ liệu thực thời (Real-time Data Augmentation) có triệt tiêu hiện tượng quá khớp (Overfitting) hay không, chúng ta phân tích trực tiếp dòng chảy dữ liệu huấn luyện lưu trong file lịch sử `cnn_history.json`:

- **Giai đoạn khởi tạo (Epoch 1):** accuracy = 40.69%, val_accuracy = 22.06%. Sự chênh lệch ban đầu cao do mô hình đang bắt đầu học phân phối.
- **Giai đoạn giữa kỳ (Epoch 10):** accuracy tăng mạnh lên 81.11%, đường xác thực kiểm thử val_accuracy bám đuôi sát sao ở mức 79.68% Khoảng cách (gap) thu hẹp chỉ còn 1.43%
- **Giai đoạn hội tụ cuối (Epoch 20):** Mô hình đạt trạng thái cực kỳ lý tưởng khi accuracy tập Train đạt 87.82%, đồng thời val_accuracy đạt mốc cao ấn tượng

85.24%. Khoảng sai lệch phân kỳ cực nhỏ (~2.58%). Quan trọng hơn, hàm mất mát loss (0.3462) và val_loss (0.4479) đồng thời giảm tuyến tính đều đặn mà không hề có hiện tượng đường xác thực đi lên ngược chiều.

Kết luận:

Các minh chứng từ số liệu đồ thị khẳng định **Data Augmentation đã phát huy tác dụng xuất sắc để kiểm soát Overfitting**. Trong mã nguồn classifier.py, việc cấu hình các tầng lật ảnh (RandomFlip), xoay góc (RandomRotation), tịnh tiến (RandomTranslation) và thu phóng hình ảnh (RandomZoom) đã liên tục tạo ra các mẫu dị biệt trong từng mini-batch. Cơ chế này ngăn chặn mạng Neural ghi nhớ máy móc tọa độ cố định của pixel, bắt buộc các bộ lọc tích chập phải tập trung học các đặc trưng hình thể có tính bao quát, tổng quát hóa cao (Generalization).

4. Cải tiến đơn lẻ mang lại hiệu quả cao nhất xét trên độ phức tạp kiến trúc

Xét theo tỷ lệ hiệu năng thặng dư nhận được trên độ phức tạp tính toán bổ sung (Gain per added complexity), việc **tích hợp thêm khối tích chập sâu thứ 3 (Deeper CNN Block 3 với 128 bộ lọc) kết hợp chuẩn hóa Batch Normalization** chính là bước đi mang tính đột phá nhất trong bài thí nghiệm này.

- **Bứt phá mục tiêu đề bài:** Trong hướng dẫn bài tập, đích tham chiếu thông thường cho một mạng CNN cơ bản (không augmentation) chỉ dao động quanh mốc 70% - 78% độ chính xác. Tuy nhiên, nhờ kiến trúc cải tiến sâu gồm 3 Khối tích chập lồng ghép chặt chẽ trong mã nguồn thực tế, mô hình của bạn đã nhảy vọt đạt thẳng tới **84.31% Test Accuracy**.
 - **Giải thích bản chất cơ chế hoạt động:**
 - *Deeper CNN Block 3:* Việc mở rộng chiều sâu mạng giúp tăng trường tiếp thụ (Receptive Field). Các lớp đầu chỉ học đặc trưng sơ cấp thô (cạnh, sọc), lớp 3 (Conv2D 128 filters) bắt đầu tổng hợp được các **đặc trưng ngữ nghĩa trừu tượng cấp cao (High-level Semantic Features)** như hình thái bánh xe, kết cấu mắt tai động vật.
 - *Batch Normalization (BN):* Đóng vai trò giảm thiểu hiện tượng **Dịch chuyển đồng biến nội bộ (Internal Covariate Shift)** bằng cách chuẩn hóa phân phối đầu ra của mỗi lớp. BN ổn định hóa dòng Gradient lan truyền ngược, triệt tiêu nguy cơ tiêu biến/bùng nổ gradient (Vanishing/Exploding Gradient), cho phép mô hình hội tụ ở tốc độ cực nhanh với Learning Rate cao mà không bị mất ổn định hệ thống.
-

5. Định hướng thử nghiệm tiếp theo nếu có thêm gấp đôi thời gian huấn luyện

Dựa trên nền tảng các mô hình và mã nguồn được thiết kế sẵn trong lớp học phần (classifier.py, main.py) cùng các gợi ý nghiên cứu, ba hành động thực nghiệm tối ưu tiếp theo bao gồm:

- **Triển khai huấn luyện toàn diện cấu hình lớp CIFARCNNImprovedClassifier:**
Tận dụng quỹ thời gian dồi dào gấp đôi để mở rộng số lượng vòng lặp huấn luyện lên tối đa **60 epochs** (thay vì giới hạn ở mức 20 epochs thấp như trước đây). Việc tăng epoch này sẽ được kiểm soát an toàn tuyệt đối và tối ưu hóa thông qua cơ chế tích hợp đồng thời hai Callbacks nâng cao: EarlyStopping (tự động theo dõi độ chính xác kiểm định và ngắt sớm nếu sau 10 epochs không sinh tiến triển mới nhằm chống lãng phí thời gian) phối hợp cùng ReduceLROnPlateau (tự động cắt giảm 50% tỉ lệ học tập learning rate khi phát hiện val_loss bị bão hòa, giúp mô hình chuyển hướng mượt mà, len lỏi sâu và hội tụ ổn định vào điểm tối ưu toàn cục).
- **Tái cấu trúc kiến trúc đầu ra bằng GlobalAveragePooling2D thay thế Flatten:** Theo định hướng bài toán nghiên cứu nhỏ (Task 5), việc loại bỏ tầng Flatten kết nối đầy đủ truyền thống để thay thế bằng tầng lấy mẫu trung bình toàn cục giúp thu gọn toàn bộ bản đồ đặc trưng 2D về một giá trị đại diện duy nhất. Phương án này triệt tiêu một lượng cực lớn tham số kết nối dư thừa ở phần đầu phân loại (classifier head), trực tiếp làm giảm độ phức tạp tính toán và tạo ra một tấm màn lọc tự nhiên ngăn chặn hành vi học vẹt (Overfitting) vô cùng hiệu quả.
- **Thực nghiệm nâng cao với Transfer Learning bằng xương sống MobileNetV2:** Tiến hành khai thác tính năng học chuyển đổi (Transfer Learning) bằng cách tích hợp một mạng nơ-ron gọn nhẹ được tiền huấn luyện vững chắc trên cơ sở dữ liệu triệu ảnh ImageNet là MobileNetV2, tinh chỉnh lớp Input phù hợp với chiều ảnh 32x32. Điều này cho phép mô hình thừa hưởng ngay các bộ trích xuất tri thức thị giác cao cấp có sẵn từ thế giới thực, giúp so sánh đối chiếu trực quan về cả tốc độ hội tụ lẫn độ chính xác tối thượng thu được so với mô hình thiết kế thủ công Custom CNN ban đầu.